

UNIVERSIDADE DO VALE DO RIO DOS SINOS – UNISINOS

MBA EM INTELIGÊNCIA ARTIFICIAL APLICADA

SEGMENTAÇÃO DE CLIENTES COM APRENDIZADO NÃO SUPERVISIONADO

Atividade Prática 01

Disciplina: Aprendizado de Máquina Não Supervisionado

Aluno: Matheus Teixeira Rohde

Professor: Cassiano Ricardo Neubauer Moralles

Sumário Executivo

Este trabalho teve como objetivo segmentar clientes do dataset Online Retail utilizando técnicas de aprendizado não supervisionado a partir das variáveis Recency, Frequency e Monetary (RFM). Após a preparação dos dados, foram analisados 4.338 clientes e comparados três métodos de clustering: K-Means, clustering hierárquico e DBSCAN.

Entre as soluções avaliadas, o K-Means com quatro clusters apresentou o melhor desempenho geral, com Silhouette Score de 0,338, Davies-Bouldin de 1,009 e Calinski-Harabasz de 3.328,338. Além dos resultados das métricas, essa solução permitiu identificar grupos com comportamentos de compra diferentes e de fácil interpretação.

Principais descobertas:

- Foram identificados quatro segmentos: clientes de alto valor, clientes pouco ativos, clientes recentes de baixa frequência e clientes intermediários.
- O segmento de clientes de alto valor reúne 713 clientes e concentra 64,89% do valor total gasto, além de apresentar compras mais recentes e maior frequência.
- O segmento de clientes pouco ativos é o maior, com 1.622 clientes, e apresenta maior tempo desde a última compra, baixa frequência e baixo gasto.

Top 3 recomendações prioritárias:

- Priorizar ações de retenção e fidelização dos clientes de alto valor, considerando sua elevada participação no valor total gasto.
- Desenvolver ações de reativação para os clientes pouco ativos, buscando estimular novas compras.
- Estimular novas compras entre os clientes recentes de baixa frequência, buscando desenvolver o relacionamento e aumentar sua frequência e valor gasto.

Os resultados mostram que técnicas de clustering podem ajudar a identificar diferentes padrões de comportamento de compra e apoiar a definição de estratégias de relacionamento com os clientes.

Metodologia

Foi utilizado o dataset Online Retail, composto por transações de uma empresa varejista entre dezembro de 2010 e dezembro de 2011. Inicialmente, foi realizada a inspeção e limpeza dos dados, com tratamento de valores ausentes, registros duplicados, cancelamentos e transações com quantidades ou preços inválidos. Após essa etapa, a base passou de 541.909 para 392.692 transações válidas, correspondentes a 4.338 clientes.

Para representar o comportamento de cada cliente, foram construídas três variáveis do modelo RFM:

- Recency: número de dias desde a última compra;
- Frequency: quantidade de compras distintas realizadas pelo cliente;
- Monetary: valor total gasto pelo cliente no período analisado.

Como essas variáveis apresentavam distribuições assimétricas e valores extremos, foi aplicada uma transformação logarítmica para reduzir a influência dos valores mais elevados. Em seguida, os dados foram padronizados com StandardScaler para que as três variáveis ficassem em escalas comparáveis antes da aplicação dos algoritmos de clustering.

Foram comparados três algoritmos de agrupamento: K-Means, clustering hierárquico e DBSCAN. No K-Means, diferentes números de clusters foram avaliados pelo método do cotovelo e pelo Silhouette Score, além da análise da estabilidade da solução. No clustering hierárquico, foram comparados os métodos de ligação Ward, Complete e Average, além da análise do dendrograma. Para o DBSCAN, o parâmetro *eps* foi definido com auxílio do gráfico k-distance.

Resultados e Insights

A aplicação dos três algoritmos resultou em diferentes formas de segmentação dos clientes. No K-Means, foram avaliadas diferentes quantidades de clusters por meio do método do cotovelo e do Silhouette Score. Embora a solução com dois clusters tenha alcançado o maior Silhouette Score, a escolha de quatro clusters possibilitou uma divisão mais detalhada e útil para a interpretação dos perfis. O modelo também se mostrou estável em diferentes inicializações, com valores do índice de Rand ajustado (ARI) entre 0,93 e 0,95.

No clustering hierárquico, foram comparados os métodos Ward, Complete e Average. O Average obteve o maior Silhouette Score (0,432), porém concentrou 4.290 dos 4.338 clientes em um único cluster. O método Ward gerou grupos mais equilibrados e, por esse motivo, foi escolhido como a melhor solução entre os métodos hierárquicos avaliados.

O DBSCAN, utilizando *eps* = 0,4 e *min_samples* = 10, identificou três clusters e classificou 166 clientes (3,83%) como ruído.

Comparação dos algoritmos

Algoritmo	Silhouette ↑	Davies-Bouldin ↓	Calinski-Harabasz ↑
K-Means (4 clusters)	0,338	1,009	3.328,338

Hierárquico (Ward)	0,280	1,099	2.739,570
DBSCAN	0,175	1,689	2.079,212

O K-Means apresentou o melhor desempenho geral nas três métricas. Além disso, os quatro grupos apresentaram diferenças relevantes em recência, frequência e valor gasto. Por esses motivos, o K-Means com quatro clusters foi escolhido como solução final.

Perfis identificados

A segmentação final identificou quatro perfis:

- Cluster 0 – Clientes de alto valor: 713 clientes, com compras mais recentes, maior frequência e maior gasto. O grupo concentra 64,89% do valor total gasto.
- Cluster 1 – Clientes pouco ativos: 1.622 clientes, caracterizados pelo maior tempo desde a última compra, baixa frequência e baixo gasto.
- Cluster 2 – Clientes recentes de baixa frequência: 837 clientes, com compras recentes, mas frequência e gasto ainda baixos.
- Cluster 3 – Clientes intermediários: 1.166 clientes, com frequência e gasto acima da média, porém abaixo dos níveis observados no grupo de alto valor.

A análise por PCA mostrou que os dois primeiros componentes principais preservaram 93,87% da variância dos dados, permitindo representar os quatro grupos em duas dimensões sem grande perda de informação. A visualização ajudou a observar tanto as diferenças quanto as regiões de maior proximidade entre os clusters.

Recomendações de Negócio

A segmentação permite pensar em estratégias diferentes de relacionamento para cada perfil de cliente:

- Cluster 0 – Clientes de alto valor: priorizar ações de retenção e fidelização, considerando a alta frequência de compra e a concentração de 64,89% do valor total gasto nesse grupo. Essa concentração também representa um ponto de atenção, já que a perda desses clientes pode gerar um impacto relevante nos resultados.

- Cluster 1 – Clientes pouco ativos: desenvolver ações de reativação para estimular novas compras. O maior tempo desde a última compra, combinado com baixa frequência e baixo gasto, indica maior risco de afastamento em relação aos demais segmentos.
- Cluster 2 – Clientes recentes de baixa frequência: estimular novas compras e buscar aumentar a frequência e o valor gasto. Como esses clientes compraram recentemente, existe uma oportunidade de desenvolver o relacionamento com esse grupo.
- Cluster 3 – Clientes intermediários: desenvolver ações para aumentar a frequência e o valor das compras, buscando fortalecer o relacionamento com clientes que já apresentam comportamento acima da média, mas ainda abaixo do segmento de maior valor.

Essas recomendações devem ser entendidas como hipóteses de ação baseadas nos padrões encontrados nos dados. Seus resultados precisam ser avaliados posteriormente por meio de testes e indicadores de negócio.

Limitações e Conclusão

A análise apresenta algumas limitações importantes. O modelo RFM resume o comportamento dos clientes em três variáveis e, por isso, não representa toda a trajetória de compra. A variável *Recency*, por exemplo, considera apenas a última compra, o que faz com que clientes com históricos diferentes possam apresentar valores semelhantes. Além disso, os valores extremos de frequência e gasto foram mantidos por poderem representar comportamentos reais de compra, embora possam influenciar a formação dos grupos.

A escolha de quatro clusters também não significa que existam quatro tipos naturais de clientes na base. A definição da solução final considerou tanto as métricas de avaliação quanto o equilíbrio e a possibilidade de interpretação dos segmentos. Da mesma forma, as recomendações apresentadas são hipóteses baseadas nos padrões encontrados nos dados e não indicam relações de causa e efeito.

Mesmo considerando essas limitações, o K-Means com quatro clusters apresentou o melhor resultado geral entre os algoritmos comparados e gerou grupos com diferenças relevantes em recência, frequência e valor gasto. Um dos principais achados foi a concentração de 64,89% do valor total gasto no segmento de clientes de alto valor.

De forma geral, a análise permitiu identificar diferentes padrões de comportamento de compra e mostrou como técnicas de aprendizado não supervisionado podem apoiar decisões de relacionamento, retenção, reativação e desenvolvimento de clientes.

Repositório do Projeto

O notebook e o código utilizados nesta análise estão disponíveis no repositório do projeto no GitHub:

<https://github.com/Matrohde/segmentacao-clientes-aprendizado-nao-supervisionado>